N.O.V.A. 2026

run_agent 실행 흐름과 agent 진료 실제 예시

Navigating **O**ptimal clinical decisions via **V**irtual-patient **A**gents

2026. 10. 11. · 대회 서버에서 실제로 주고받은 요청·응답으로 작성

주최/주관 의료인공지능센터 Center for Artificial Intelligence in Healthcare /* elice */

후원 GBSA 경기도경제과학진흥원 IITP 정보통신기획평가원 KHIDI 한국보건산업진흥원

01

run_agent 실행 흐름

prepare → ready → consult → diagnose → 채점, 서버 안에서 일어나는 일

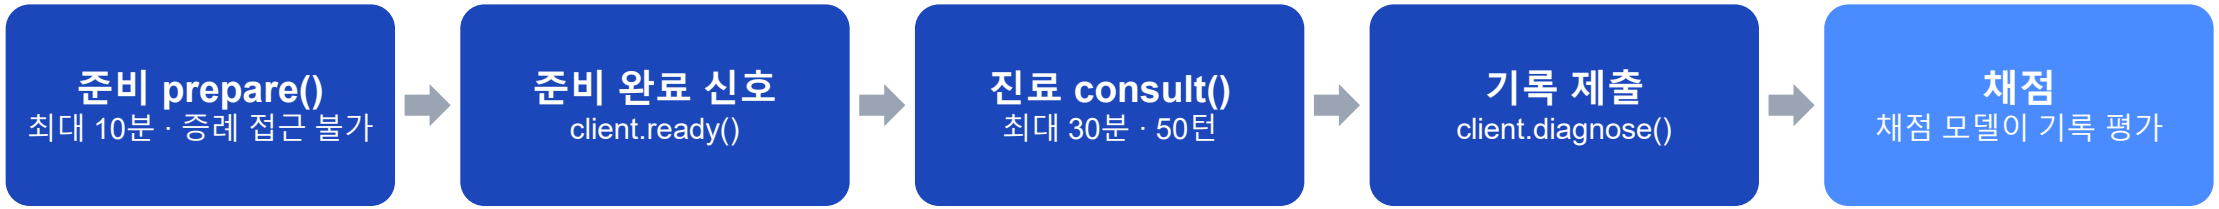
SNUH 분당서울대학교병원
SEOUL NATIONAL UNIVERSITY BUNDANG HOSPITAL
건강한 미래의 지평을 여는 국민의 병원
Lead the Future, Enhance Trust

한눈에 보기

SNUH 분당서울대학교병원 SEOUL NATIONAL UNIVERSITY BUNDANG HOSPITAL

참가자가 만드는 것은 run.py 하나이고, 그 안의 두 함수가 핵심

- **prepare()** — 진료 전에 한 번. 모델·검색 자료 같은 것을 불러옴. 이때는 환자 정보에 접근할 수 없음
- **consult(client, state)** — 진료. client로 환자에게 묻고(SAY), 진찰하고(EXAM), Doctor 모델을 부르고(chat), 마지막에 기록을 제출(DIAGNOSE)
- **run_agent(prepare, consult)**는 이 둘을 정해진 순서로 이어 주는 SDK 함수. 순서는 늘 같음



컨테이너 서버는 증례마다 새 컨테이너를 띄워 python run.py를 실행합니다. 증례 5개를 평가하면 이 과정이 5번 반복되고, 증례끼리 메모리나 파일을 공유하지 않습니다.

의료인공지능센터 Center for Artificial Intelligence in Healthcare

run.py와 run_agent

SDK의 run_agent (nova_sdk.py, 전체)

```
def run_agent(prepare, consult):
    client = Client()     # 환경변수 NOVA_API_BASE,
                          # NOVA_RUN_TOKEN, NOVA_SESSION_ID
    state = prepare()     # ① 준비: 모델·자료 로드
    client.ready()        # ② 준비 완료 → 진료 30분 시작
    return consult(client, state)    # ③ 진료
```

참가자 run.py의 뼈대 (시작 패키지 기본 에이전트)

```
from nova_sdk import RECORD_FIELDS, NovaError, empty_record,
run_agent

def prepare():                # 예선: 준비할 모델 없음
    return None

def consult(client, model):
    session = client.session()    # 시작 정보·남은 턴·마감
    ...    # 매 턴: client.chat() → client.say() / client.exam()
    note, diagnosis = write_record(client, session, transcript)
    return client.diagnose(note=note, diagnosis=diagnosis)

if __name__ == '__main__':
    run_agent(prepare, consult)    # ← 서버가 python run.py로 실행
```

꼭 알아 둘 것

- 맨 아래 **if __name__ == '__main__': run_agent(prepare, consult)** 줄이 없으면 아무 진료도 하지 않고 끝나 해당 증례는 실패
- 모든 요청에 **request_id**가 붙음. 같은 번호로 다시 보내면 서버는 새로 처리하지 않고 처음 응답을 그대로 돌려줌 → 네트워크가 끊겨 재전송해도 턴이 두 번 쓰이지 않음
- SAY·EXAM·TEST의 **30자 검사**는 SDK가 서버로 보내기 전에 먼저 함(ValueError, 보내지 않았으니 턴도 안 씀). 서버도 한 번 더 검사(400 CONTENT_TOO_LONG, 이때는 1턴 사용)

서버에서 증례 하나가 도는 순서

1. **평가 요청 → 작업자가 맡음**
   샘플 검증·공식 평가 요청이 대기열에 들어가고, 평가 작업자가 하나씩 가져가 실행

2. **이미지 빌드 (제출 버전당 처음 한 번)**
   requirements.txt의 패키지를 PyPI 휠로만 설치한 Docker 이미지. 최대 20분. 실패 시 DEPENDENCY_DOWNLOAD_FAILED 등

3. **증례 세션 만들기**
   증례마다 세션 하나를 preparing 상태로 만들고, 세션 전용 실행 토큰(nvr_…)도 함께 생성

4. **컨테이너 시작**
   인터넷 없음, 읽기 전용 파일 시스템, CPU 2코어·RAM 8GB

5. **run_agent → prepare()**
   Client()가 환경변수를 읽고 prepare() 실행. 이 동안 모든 요청은 409 MODEL_NOT_READY. 10분 초과 시 prepare_timeout

6. **client.ready()**
   호스트 중계기가 세션을 active로 바꾸고 마감을 30분 뒤로 설정. 응답 {"ready": true}

7. **consult(client, state)**
   진료. 행동별로 서버 안에서 일어나는 일은 뒤 장에 실제 예시와 함께

8. **컨테이너 종료 → 결과 판정**
   0으로 종료 + ready를 보냈으면 completed, 그 외 failed · prepare_timeout · timeout(30분) · oom. 실패 사유는 제출 상세에 표시(샘플 검증은 stderr 끝 30줄도)

9. **채점**
   기록이 제출된 세션을 채점 모델이 채점. 다음 증례로 넘어가 3~9를 반복

consult 안의 행동: client가 하는 일

함수	하는 일	서버 안에서	턴	주요 오류
client.session()	시작 정보(첫 줄·활력징후), 남은 턴, 가능한 행동, 마감 시각	대본·진찰표·체크리스트는 주지 않음. 서버 실행에서는 지난 행동 기록(events)도 오지 않음	0	409 MODEL_NOT_READY (ready 전)
client.chat()	Doctor 모델(gpt-oss-20b)을 OpenAI 형식으로 호출	한도 확인(세션당 200회 · 입력 50만 · 출력 10만 토큰) → 엘리스에 스트리밍 요청 → 완성된 답을 한 번에 돌려줌	0	403 MODEL_NOT_ALLOWED 400 INVALID_COMPLETION_FIELDS 503 PROVIDER_RESPONSE_INVALID (빈 답)
client.say()	환자에게 질문·설명 (1~30자, 한 번에 하나)	가상 환자 모델(gpt-6.1-sol low)에 규칙 + 비공개 지시문 + 대본 + 대화를 보냄 → {content, effective_content}. 형식 오류면 503을 돌려줌(참가자 코드가 다시 보냄)	1	400 CONTENT_TOO_LONG · EMPTY_CONTENT (1턴) 503 PATIENT_RESPONSE_INVALID (0턴)
client.exam()	신체진찰 동작 하나를 문장으로 요청	진찰 판정 모델(gpt-6.1-sol low)이 진찰표 행 하나에 연결 → 서버가 그 행의 정해진 결과를 돌려줌 (모델이 소견을 지어낼 수 없음)	1	422 EXAM_NOT_SPECIFIC · EXAM_NOT_RECOGNIZED (1턴) 503 EXAMINER_RESPONSE_INVALID (0턴)
client.diagnose()	S·O·A·P 15칸(빈 문자열 가능, 전부 비면 안 됨) + 주진단 한 줄 제출	세션 종료, 채점용 기록 텍스트(note) 생성, record_digest 반환. score_status는 pending	0	이후 모든 요청은 409 SESSION_CLOSED

Doctor 모델 호출: client.chat()

SNUH 분당서울대학교병원 SEOUL NATIONAL UNIVERSITY BUNDANG HOSPITAL

보낸 것 (POST /v1/chat/completions)

```
{
  "request_id": "doc-chat-1",
  "messages": [
    {"role": "system",
     "content": "다음 행동을 JSON으로만 답하세요.
                 {\"action\":\"SAY\",\"content\":\"질문\"}"},
    {"role": "user",
     "content": "시작 정보: 저는 박선희이고, 예순두 살
                 여자이다. … 다음 행동:"}
  ],
  "max_tokens": 1024, "reasoning_effort": "medium",
  "temperature": 0.7, "session_id": "fd3eea4d-…"
}
```

받은 것 (OpenAI 형식)

```
{
  "id": "3ccc5ed6-…", "object": "chat.completion",
  "model": "openai/gpt-oss-20b",
  "choices": [{"index": 0, "finish_reason": "stop",
    "message": {"role": "assistant",
      "content": "{\"action\":\"SAY\",\"content\":
        \"현재 수면 패턴이나 생활 습관에 대해 좀 더
        자세히 말씀해 주실 수 있나요?\"}"}}],
  "usage": {"prompt_tokens": 140, "completion_tokens": 267,
            "total_tokens": 407}
}
```

- 예선에서는 **gpt-oss-20b**만 쓸 수 있음(model을 다르게 주면 403 MODEL_NOT_ALLOWED). 서버가 Doctor 설정을 고정 버전으로 잠금
- 참가자가 정할 수 있는 것은 **messages, max_tokens, reasoning_effort(low·medium·high), temperature(0~2)**뿐. tools·stream·response_format 등을 넣으면 400 INVALID_COMPLETION_FIELDS
- completion_tokens 267에는 화면에 안 보이는 **추론 토큰**이 포함. 이 답은 42자라 30자를 넘으므로, 기본 에이전트였다면 버리고 다시 물었을 것
- 답이 비어 있으면(추론만 하고 끝난 경우) **503 PROVIDER_RESPONSE_INVALID**. 팀 요금·토큰 한도·효율 점수의 Doctor 비용에 넣지 않고 **호출 200회에만 셈**. 턴은 어떤 경우에도 쓰지 않음
- GPT-OSS-20B의 경우에는 답을 비워 출력하는 경우가 있으니 처리 필요.

진찰(EXAM) 요청은 어떻게 판정되나

판정	서버 동작	턴	실제 예시 (요청 → 응답)
진찰표 행에 연결	그 행의 정해진 결과를 돌려줌. 서버 기록에 effective_content로 그 행 이름이 남아 채점 때 "어떤 진찰을 했는지"의 근거가 됨	1	"양손을 앞으로 뻗게 해 떨림을 보겠습니다" → **자세성 떨림(-/-)**
진찰표에 없는 실제 진찰 (unlisted)	모델이 시작 정보·진찰표(결과 포함)를 보고 같은 형식의 소견을 지어 답함. 기본은 정상 소견, 새 이상 소견은 만들지 않음. 증례·진찰별로 저장해 어느 팀이든 같은 답	1	"무릎 반사를 보겠습니다" → **슬개건 반사 2+/2+, 대칭**
뭉뚱그리거나 특정 불가 (too_broad)	422 EXAM_NOT_SPECIFIC. 꽤 구체적으로 보여도 진찰 방법이 여러 가지면 거절(자세성 떨림인지 안정시 떨림인지)	1	"신체검진 다 해 주세요" · "손 떨림 확인하겠습니다" → **EXAM_NOT_SPECIFIC**
신체진찰이 아님 (not_exam)	422 EXAM_NOT_RECOGNIZED. 문진·혈액·영상 검사·처치·기록 작성 등. 진찰이냐 아니냐는 증례와 무관하므로 이 거절로는 진찰표 내용을 알 수 없음	1	"수면 일지를 작성하겠습니다" → **EXAM_NOT_RECOGNIZED**
판정 모델 형식 오류	503 EXAMINER_RESPONSE_INVALID. 서버 쪽 실패	0	참가자 코드가 받아서 다시 시도

잘못 보낸 진찰 요청도 1턴을 씁니다. 거절 응답에도 turn·turns_remaining이 붙고, 같은 request_id로 다시 보내면 같은 거절이 돌아오며 턴을 또 쓰지는 않습니다. 진찰표에 없는 진찰에도 소견을 지어 답하는 이유: 늘 "특이 소견 없음"이라고 답하면 어떤 진찰이 표에 있는지 추론할 수 있기 때문입니다.

턴 계산 예시: 대회 서버, 공개 샘플 C01

순서	행동	보낸 내용	결과	HTTP	사용한 턴
1	**SAY**	언제부터 잠을 못 주무셨나요?	한 7년 전부터요.	200	**1**
2	**SAY**	증상을 전부 말씀해 주세요	**한 번에 하나씩 물어봐 주세요. (뭉뚱그린 질문)**	200	**2**
3	**EXAM**	손 떨림 확인하겠습니다	**EXAM_NOT_SPECIFIC**	422	**3**
4	**EXAM**	양손을 앞으로 뻗게 해 떨림을 보겠습니다	자세성 떨림(-/-)	200	**4**
5	**EXAM**	무릎 반사를 보겠습니다	**슬개건 반사 2+/2+, 대칭 (진찰표에 없음 → 소견 작성)**	200	**5**
6	**EXAM**	신체검진 다 해 주세요	**EXAM_NOT_SPECIFIC**	422	**6**
7	**EXAM**	수면 일지를 작성하겠습니다	**EXAM_NOT_RECOGNIZED**	422	**7**
8	**SAY**	가가가가가… (31자, SDK를 거치지 않고 직접 전송)	**CONTENT_TOO_LONG**	400	**8**
9	**DIAGNOSE**	주진단 "수면제 의존" + 기록	completed	200	**8**

- 잘못 보낸 요청(422 진찰 거절, 400 30자 초과)도 턴 숫자가 1씩 늘고, DIAGNOSE에서는 늘지 않습니다. 서버 쪽 모델 실패(503)였다면 늘지 않습니다.
- SDK를 쓰면 30자 초과는 서버로 보내기 전에 ValueError로 막혀 턴을 쓰지 않습니다. 8번은 SDK를 거치지 않고 HTTP로 직접 보낸 경우입니다.

진료가 끝난 뒤: 판정과 채점

실행 종류	통과·실패 판정	채점	점수를 보는 사람
개발 키 샘플 진료 (sample.py)	없음	안 함	—
샘플 검증 (제출 ZIP, 공개 샘플 3건)	모든 증례가 끝까지 돌고 기록을 냈고, 예선이면 Doctor 모델을 1번 이상 불렀는가	가상 환자·진찰 판정·채점 모두 gpt-6-luna (low·low·medium). 채점 실패 시 1번 더 시도. 점수가 없어도 통과·실패는 그대로	우리 팀만 (참고 점수)
공식 평가 (리더보드 5증례)	Doctor 모델 미호출 증례는 0점	임상 채점·진단 판정 gpt-6.1-sol high, 친절도 gpt-6.1-sol low → 6개 영역 100점 → 증례 평균	리더보드는 총점, 영역별 점수는 우리 팀만
예선 최종 평가 (10증례)	같음	GPT · Claude · Gemini 세 모델 채점의 평균	최종 순위

채점 모델이 받는 것

- 서버에 기록된 대화·진찰 기록, 제출한 기록 텍스트, 비공개 루브릭(문진·진찰·검사·설명·안전 항목). **참가자의 Doctor 프롬프트는 받지 않음**
- 질문하지 않고 기록에만 적은 내용은 **"수행"으로 인정하지 않음** — 판정 근거는 기록 문장을 글자 그대로 인용해야 함

참가자 로컬(개발 키) 실행과 서버 실행의 차이

항목	개발 키트 (완전 로컬, develop.py)	개발 키 + sample.py	서버 실행 (샘플 검증·공식 평가)
코드가 도는 곳	참가자 컴퓨터		우리 서버의 격리 컨테이너, 증례마다 새로
인터넷	됨 (아무 API·다운로드 가능)		안 됨. 대회 API만. 실행 중 모델·데이터 다운로드는 실패
패키지 · 자원	내 컴퓨터에 깔린 것 아무거나 · 내 컴퓨터 사양 (GPU 가능)		requirements.txt의 PyPI 휠만(빌드 20분) · CPU 2코어 · RAM 8GB · GPU 없음
파일 쓰기	어디든		읽기 전용. /tmp(512MB)와 /output만. 홈 폴더 캐시(Hugging Face 등)는 실패
인증 · 세션	없음 · develop.py가 세션을 만듦	개인 개발 키(NOVA_DEV_KEY) · 참가자 코드가 직접(create_sample)	증례별 임시 토큰 · 서버가 미리 만들어 NOVA_SESSION_ID로 줌
준비 단계	사실상 없음. ready()는 아무 일도 안 함		prepare() 10분 제한, 그동안 증례 접근 차단, ready() 필수
진료 시간	30분 (바꿀 수 있음)	세션을 만든 때부터 30분	ready 후 30분, 넘으면 컨테이너 강제 종료
가상 환자 · 진찰 판정	참가자가 고른 모델 + 개발 키트용 지시문	gpt-6.1-sol low (공식과 같음)	샘플 검증 gpt-6-luna low, 공식 평가 gpt-6.1-sol
비용 · 채점	참가자 부담 · 채점 안 함	팀 크레딧 차감 · 채점 안 함	운영진 부담 · 샘플 검증 luna 참고 점수, 공식 평가 sol 채점
오류·출력 보기	화면에 다 보임		샘플 검증: 증례별 사유 + stderr 끝 30줄 · 리더보드: 사유만
session() 응답	시작 정보만	시작 정보 + 지금까지의 행동 기록·제출 기록·점수 칸	시작 정보만

참가자가 자주 겪을 차이 세 가지

SNUH 분당서울대학교병원 SEOUL NATIONAL UNIVERSITY BUNDANG HOSPITAL

서버에 내기 전에 코드를 돌려 보는 방법은 두 가지

개발 키트 — **develop.py** — 서버 없이 내 컴퓨터에서 전부 흉내 냄. 가상 환자도 참가자가 고른 모델

개발 키 + sample.py — 코드는 내 컴퓨터에서 돌고, 가상 환자·진찰 판정·Doctor 모델은 우리 서버 것을 씀

① 로컬은 되는데 서버는 실패

실행 중 인터넷 다운로드
홈 폴더에 캐시 쓰기 (Hugging Face 등)
requirements.txt에 없는 패키지
8GB를 넘는 메모리
→ **모두 서버에서 실패**

② 로그는 일부만 보임

서버에서 실패하면 샘플 검증은 증례별 사유와 stderr 끝 30줄만, 리더보드 평가는 사유만 보임
개발 키트와 시작 패키지의 **local.Dockerfile**(인터넷 없이 읽기 전용으로 실행)로 먼저 확인해야 함

③ session() 응답 차이

개발 키 샘플에서는 지난 행동 기록(events)이 함께 오지만 서버 실행에서는 오지 않음
대화 기록은 참가자 코드가 **직접 들고 있어야 함** (기본 에이전트처럼)

02

C01 진료 실제 예시

기본 에이전트가 공개 샘플 C01을 진료한 30턴, 호출 하나하나와 채점

SNUH 분당서울대학교병원
SEOUL NATIONAL UNIVERSITY BUNDANG HOSPITAL

건강한 미래의 지평을 여는 국민의 병원
Lead the Future, Enhance Trust

C01 진료 개요

SNUH 분당서울대학교병원 SEOUL NATIONAL UNIVERSITY BUNDANG HOSPITAL

증례 C01 · 62세 여성 · 정답 진단 **수면제 의존 (Sedative-Hypnotic Use Disorder)**

진료 기본 에이전트(sdk/run.py, Doctor 추론 강도 medium)를 개발 키로 실행 · 최종 진단 **주요 불면증 (오진)**

기준 2026-10-11 오후 대회 서버(개발 키), 그날 바뀐 규칙 모두 반영 · 같은 세션을 공식 평가와 같은 채점 모델(gpt-6.1-sol)로 채점

30턴
진료 턴 (그중 진찰 거절 6턴)

4분 20초
07:30:18 시작 → 07:34:39 제출 (제한 30분)

69회
Doctor 37 · 가상 환자 20 · 진찰 판정 10 + 소견 작성 2

41.2점
100점 만점 (채점 3회)

정보수집 (25)	진단추론 (15)	검사·추적 (10)	안전 (15)	의사소통 (15)	효율 (20)
3.819	4.167	0.000	11.250	2.000	20.000

서버에 남은 모든 모델 호출(보낸 메시지와 받은 답)과 행동 기록을 그대로 옮긴 예시입니다. 대본·진찰표·모범 기록은 공개 샘플 ZIP과 같습니다.

등장하는 모델과 프롬프트

역할	모델	프롬프트
Doctor (참가자 에이전트)	gpt-oss-20b	참가자 (여기서는 기본 에이전트)
가상 환자	gpt-6.1-sol (low)	서버: 공통 규칙 + 환자 지시문 + 대본
진찰 판정	gpt-6.1-sol (low)	서버: 진찰 판정 규칙 + 진찰표 이름 목록
소견 작성	gpt-6.1-sol (low)	서버: 소견 작성 규칙 + 시작 정보 + 진찰표
임상 채점	gpt-6.1-sol (high)	서버: 채점 규칙 + 채점 위원 지시문
친절도	gpt-6.1-sol (low)	서버: 친절도 규칙 + 평가 지시문
진단 판정	gpt-6.1-sol (high)	서버: 5점 척도 규칙 (Sequential Diagnosis with Language Models, Nori et al. Microsoft AI, 2025)

한 턴의 흐름 (기본 에이전트)

SNUH 분당서울대학교병원

① **Doctor에 "다음 행동" 질문**
client.chat(reasoning_effort=medium)

② **답(JSON) 검사**
30자·형식 확인 후 SAY / EXAM 전송

③ **서버가 모델 호출**
가상 환자 또는 진찰 판정

④ **결과를 진료 기록에 붙임**
다음 턴의 사용자 메시지로

Doctor 프롬프트 (기본 에이전트)

- **시스템:** 외래 진료실 의사 역할. 매번 JSON 하나만 출력 — {"action":"SAY","content":"…"}(30자 이내) · {"action":"EXAM","content":"진찰 동작 하나"} · {"action":"DONE"}
- **진행 순서:** 주호소 → 현병력 → 과거력·약·알레르기 → 가족력 → 사회력 → 계통 문진 → 관련 신체 진찰 → 진단·계획 설명 → DONE. 질문은 한 번에 하나, 이미 물은 것은 다시 묻지 않음
- **사용자 메시지:** 매 턴 새로 생성 — 시작 정보 + 진료 기록(대화가 한 줄씩 쌓임) + 남은 턴. 남은 턴 ≤10이면 "문진을 마무리하고 EXAM", ≤2이면 "진단과 계획을 쉬운 말로 설명(SAY)" 지시가 덧붙음
- **서버가 엘리스로 보낸 설정:** max_completion_tokens 2048, stream, reasoning_effort medium. temperature는 보내지 않아 모델 기본값

재시도 규칙

- **빈 답(503 PROVIDER_RESPONSE_INVALID):** 2초·5초·10초 기다렸다가 같은 내용으로 다시 물음(with_retry)
- **30자 초과·형식 오류:** 답을 버리고 "직전 출력은 형식에 맞지 않았습니다. 30자 이내의 JSON 하나만 출력하세요."를 붙여 바로 다시 물음(next_step, 최대 3번)
- **진찰 거절(422):** 답 없이 1턴이 줄고, "(알림: 오류 코드, 1턴 사용. …)"을 진료 기록에 붙여 다음 행동을 고를 때 참고하게 함
- **턴 소진(MAX_TURNS = 30, 대회 한도는 50):** 진료를 멈추고 write_record()로 초진 기록 작성 → client.diagnose()

턴 1을 호출 단위로 따라가기

Doctor 요청

gpt-oss-20b

```
시작 정보 / 첫 진술: 저는 박선희이고, 예순두 살 여자이다. 잠을 잘 못 자서 병원에 왔다. 수면제를 처방해 달라고 왔다.
활력징후: 혈압 128/78 mmHg · 맥박 76 회/분 · 호흡 18 회/분 · 체온 36.6°C
진료 기록 / (아직 없음)  ·  남은 턴: 30  ·  다음 행동:
```

Doctor 답

입력 421 · 출력 164 토큰

```
{"action":"SAY","content":"잠을 못 잘기 시작은 언제에요?"}
```

SDK 요청

client.say(…) → POST …/actions

```
{"request_id": "5cf42d04-e410-423e-85fd-f513f3ec03e2", "action": "SAY", "content": "잠을 못 잘기 시작은 언제에요?"}
```

서버 → 가상 환자

gpt-6.1-sol low · 1.4초

```
보냄  규칙 + 비공개 지시문 + 대본 + 지금까지의 대화 + 이번 질문
받음  {"content":"한 7년 전부터요.","effective_content":"잠을 못 잘기 시작은 언제에요?"}
```

SDK 응답

턴 1 사용

```
{"status": "OK", "content": "한 7년 전부터요.", "turn": 1, "turns_remaining": 49}
```

서버 안에서: request_id 기록(중복 방지) → 세션 상태·마감·남은 턴 확인 → 가상 환자 모델 호출 → 성공하면 턴을 1 쓰고 turn·turns_remaining을 붙여 돌려줌.

진료 30턴, 호출 하나하나 (1–15)

SNUH 분당서울대학교병원 SEOUL NATIONAL UNIVERSITY BUNDANG HOSPITAL

턴	행동	Doctor가 보낸 내용	결과	비고
1	SAY	잠을 못 잘기 시작은 언제에요?	한 7년 전부터요.	
2	SAY	수면이 몇 시간 지속돼요?	두세 시간 자고 깨요.	빈 답 2번 → 재시도 후 성공
3	SAY	수면이 더 나빠지거나 좋아지게 하는 요인은 무엇인가요?	약 안 먹으면 더 못 자고, 먹으면 좀 자요.	
4	SAY	수면 후 피로가 느껴지나요?	네, 자고 나도 개운하지 않아요.	
5	SAY	최근에 스트레스를 느끼는 일이 있나요?	약이 없으면 못 잘까 봐 불안해요.	의존 단서
6	SAY	과거 병력과 복용 약물 있으신가요?	고혈압이 있어 암로디핀 먹고, 수면제도 먹어요.	
7	SAY	알레르기나 부작용이 있으신가요?	알레르기는 없고, 낮에 많이 졸려요.	
8	SAY	가족에 수면 장애가 있나요?	가족 중엔 없는 것 같아요.	빈 답 1번 → 재시도
9	SAY	생활과 음주 습관이 궁금합니다.	집안일 하고 술은 가끔 한두 잔요.	
10	SAY	오늘 일상에 지장이 있나요?	네, 낮에 졸려 집안일이 힘들어요.	
11	SAY	수면제 종류와 용량을 알려 주세요	졸피뎀 10밀리그램, 밤에 4알, 새벽에 2알요.	30자 초과 → 재질문 · 결정적 단서
12	EXAM	수면 시 목소리 및 호흡 소리 청진하겠습니다	EXAM_NOT_RECOGNIZED (not_exam)	답 없이 1턴
13	SAY	최근 기분이 우울하거나 가라앉은 적이 있나요?	잠 못 자서 답답하지만 우울하진 않아요.	
14	SAY	하루에 커피를 얼마나 마시나요?	하루 한두 잔 마셔요.	
15	EXAM	목·어깨 긴장 확인하겠습니다	EXAM_NOT_SPECIFIC (too_broad)	답 없이 1턴

진료 30턴, 호출 하나하나 (16–30)

SNUH 분당서울대학교병원 SEOUL NATIONAL UNIVERSITY BUNDANG HOSPITAL

턴	행동	Doctor가 보낸 내용	결과	비고
16	SAY	하루 250ml 이하로 마시시나요?	두 잔 마시면 넘을 때도 있어요.	
17	SAY	밤에 코골이 하시나요?	남편 말로는 안 곤대요.	
18	EXAM	수면 자세 확인하겠습니다	EXAM_NOT_RECOGNIZED (not_exam)	답 없이 1턴
19	EXAM	목 부위 관찰하겠습니다	경부 대칭, 종창(-), 피부 발적(-), 경정맥 팽대(-)	unlisted → 소견 작성
20	SAY	수면 환경이 어두운가요?	네, 불 끄고 어둡게 자요.	
21	EXAM	눈, 귀, 코, 목을 관찰하겠습니다	EXAM_NOT_SPECIFIC (too_broad)	남은 턴 10: 문진 마무리 지시
22	EXAM	수면 패턴 기록을 확인하겠습니다	EXAM_NOT_RECOGNIZED (not_exam)	답 없이 1턴
23	EXAM	심장 청진을 하겠습니다	S1·S2 명료, 규칙적, 심잡음(-)	진찰표 행에 연결
24	EXAM	폐 청진하겠습니다	폐포음, 수포음(-/-), 천명음(-/-)	진찰표 행에 연결
25	EXAM	체중과 키를 측정하겠습니다	EXAM_NOT_SPECIFIC (too_broad)	답 없이 1턴
26	SAY	잠들기까지 얼마나 걸려요?	약 먹으면 한 30분 걸려요.	
27	SAY	최근에 가벼운 사고나 기절 경험이 있었나요?	아니요, 그런 적 없어요.	
28	EXAM	코부위 점막 검사를 하겠습니다	비점막 분홍색, 충혈(-/-), 부종(-/-), 분비물(-/-)	unlisted → 소견 작성
29	SAY	불면증. 약 조정+생활습관 개선	네, 약 줄이는 게 좀 걱정돼요.	설명 지시 · 30자 초과
30	SAY	불면증 우려, 생활습관 개선 및 약 재조정.	네, 약 줄이면 못 잘까 봐 걱정돼요.	30자 초과 → 재질문

진찰 요청 10번의 결과

턴	요청	진찰 판정	참가자가 받은 응답	턴
12	수면 시 목소리 및 호흡 소리 청진하겠습니다	신체진찰이 아님 (not_exam)	422 EXAM_NOT_RECOGNIZED	1
15	목·어깨 긴장 확인하겠습니다	뭉뚱그림·특정 불가 (too_broad)	422 EXAM_NOT_SPECIFIC	1
18	수면 자세 확인하겠습니다	신체진찰이 아님 (not_exam)	422 EXAM_NOT_RECOGNIZED	1
19	목 부위 관찰하겠습니다	표에 없는 진찰 (unlisted) → 경부 시진	소견 작성 → 경부 대칭, 종창(-), 피부 발적(-), 경정맥 팽대(-)	1
21	눈, 귀, 코, 목을 관찰하겠습니다	뭉뚱그림·특정 불가 (too_broad)	422 EXAM_NOT_SPECIFIC	1
22	수면 패턴 기록을 확인하겠습니다	신체진찰이 아님 (not_exam)	422 EXAM_NOT_RECOGNIZED	1
23	심장 청진을 하겠습니다	진찰표 행에 연결 (심장 청진)	S1·S2 명료, 규칙적, 심잡음(-)	1
24	폐 청진하겠습니다	진찰표 행에 연결 (폐 청진)	폐포음, 수포음(-/-), 천명음(-/-)	1
25	체중과 키를 측정하겠습니다	뭉뚱그림·특정 불가 (too_broad)	422 EXAM_NOT_SPECIFIC	1
28	코부위 점막 검사를 하겠습니다	표에 없는 진찰 (unlisted) → 비점막 시진	소견 작성 → 비점막 분홍색, 충혈(-/-), 부종(-/-), 분비물(-/-)	1

거절 6번 = 6턴 낭비

30턴 중 6턴을 답 없이 씀. 2026-10-11부터 거절도 턴을 쓰므로 "심장 청진", "슬개건 반사" 처럼 동작 하나로 요청해야 함

지어낸 소견 2개

경부·비점막 소견은 진찰표에 없어 모델이 정상 소견으로 작성·저장

진찰표 행 연결 2개 / 10번

진찰 요청 10번 중 심장·폐 청진 2번만 진찰표 행에 연결됨

기록 작성과 제출

write_record() → client.diagnose()

1. **30턴 소진**
   MAX_TURNS = 30에 닿아 진료 중단

2. **기록 작성 프롬프트**
   시스템: "진료 기록만 근거로 초진 기록 작성, 확인하지 않은 사실은 쓰지 않음" · 사용자: 시작 정보 + 30턴 전체 진료 기록(거절 알림 포함)

3. **Doctor 답 (입력 1,512 · 출력 1,201 토큰)**
   S·O·A·P 15칸 + 주진단이 든 JSON 하나

4. **client.diagnose(note=…, diagnosis=…)**
   POST /actions {"action":"DIAGNOSE", "note":{S,O,A,P}, "diagnosis":"주요 불면증"}

5. **응답**
   {"status":"completed", "record_digest":"c3da99c1…", "score_status":"pending", "turn":30}

제출된 기록 (서버가 채점용 note 텍스트로 변환)

칸	내용
S · CC	주호소 / Onset : 7년 전부터 불면, 약 복용 시 두세시간 수면 후 깨고 피로, 낮에 집안일이 힘듦
S · HPI	박선희 **66세** 여성(시작 정보는 62세), 7년간 불면, 수면제 복용 시 두세시간 수면 후 피로, 낮에 졸림
S · PMH	고혈압, 암로디핀, 수면제(졸피뎀) 10mg 복용, 알레르기 없음 **(밤 4알·새벽 2알 누락)**
S · FH / ROS	(비어 있음)
S · SH	흡연 없음, 알코올 1-2잔/주(들은 것은 "가끔 한두 잔"), 집안일 주업
O · 진찰	활력징후 · 경부 대칭 · 심장 청진 S1·S2 명료 · 폐 청진 정상 · 비점막 정상
A	주진단 **주요 불면증** · 근거 "7년간 불면, 수면제(졸피뎀) 복용" · 감별 r/o 수면 무호흡증, r/o 우울증
P	추가 검사 "수면다이어리, **수면주사**, …" · 치료 졸피뎀 용량 조정, CBT-I, 수면위생 · 외래 · 2주후 재진 · 교육 수면환경·카페인 제한

비용과 시간

역할	호출	비용(원)	누가 냄
Doctor (gpt-oss-20b)	37	5.91	개발 키 샘플: 팀 크레딧 서버 실행: 운영진
가상 환자 (gpt-6.1-sol)	20	68.92	같음
진찰 판정 + 소견 작성 (gpt-6.1-sol)	12	42.02	같음
합계	**69**	**116.85**	

×12

가상 환자 비용 ÷ Doctor 비용

2,753

가상 환자 요청당 평균 입력 토큰

4분 20초

진료 시간 (제한 30분)

18,183

Doctor 출력 토큰 (대부분 추론)

- 진료 자체는 4분 20초(제한 30분). 가상 환자 응답은 건당 1.2~3.3초